



Por una
universidad
de **excelencia**
y **solidaria**



Universidad
del Cauca



ISO 9001:2015 SC- CER 450832



IONet CO- SC-CER450832

PROYECTO FINAL

OPTIMIZACION DEL EFOQUE CLR MEDIANTE

ALGORITMOS GENETICOS

Estudiante: Germán Homero Morán Figueroa
Profesor: Dra. Martha Eliana Mendoza Becerra

Optimización usado Metahuristicas

Maestría en Computación
Facultad de Ingeniería Electrónica y Telecomunicaciones – FIET



CONTENIDO

1 Introducción

2 Definición del Problema

3 Metahurística

4 Resultados

5 Conclusiones

6 Bibliografía

1. INTRODUCCIÓN

GENERALIDADES

- Importancia del cultivo del maíz
- Actualmente producción nacional solo logra cubrir 80 %, 20% restante se debe a la exportación.
- Federación Nacional de Cultivadores de Cereales y Leguminosas (FENALCE).
- El departamento de córdoba aporta el 11,4% de producción nacional, con cultivos de maíz tradicional y tecnificado.
- Cada vez que un agricultor realiza una siembra existe un evento único.



2. DEFINICIÓN DEL PROBLEMA

OBJETIVO DEL NEGOCIO.

**DETERMINAR EL RENDIMIENTO DEL CULTIVO DE MAIZ
TENIENDO EN CUENTA DIFERENTE VARIABLES QUE
PUEDEN AFECTAR EL RENDIMEINTO**



FUENTES DE INFORMACIÓN

VISTA MINABLE

	TIPO_SIEMBRA	SEM_TRATADAS	DIST_SURCOS	DIST_PLANTAS	COLOR_ENDOSPERMO	SEM_POR_SITIO	MATERIAL_GENETICO	CULT_ANT	RDT_AJUSTADO
0	Mecanizado	NO	0.8	0.2	Blanco	2	PIONEER 30F32	Algodon	4767.44
1	Mecanizado	SI	0.8	0.2	Blanco	1	DK 234	Maiz	4651.16
2	Mecanizado	NO	0.8	0.2	Blanco	1	PIONEER 30F32	Algodon	5180.23
3	Mecanizado	NO	0.8	0.2	Blanco	1	Otro	Algodon	4897.67
4	Mecanizado	NO	0.8	0.2	Blanco	1	Otro	Algodon	5302.33
5	Mecanizado	SI	0.8	0.2	Blanco	2	DK 234	Maiz	4958.14
6	Manual	SI	0.8	0.2	Blanco	3	Otro	Maiz	4426.74
7	Manual	SI	0.8	0.2	Blanco	3	PIONEER 30F32	Algodon	5790.70
8	Manual	SI	0.8	0.2	Blanco	2	DK 234	Algodon	5116.28
9	Mecanizado	NO	0.8	0.2	Amarillo	1	PIONEER 30F35	Frijol	4238.37

Variables: 95

Observaciones: 747 Registros

Variables Numéricas: 64

Variables categóricas: 31



MODELADO

attribute	wei... ↓
MATERIAL_GENETICO = DK 234 YGRR	1
MATERIAL_GENETICO = DK 1596	1
POSICION_PERFIL_RASTA = PLA0 CON ONDULACIONES	1
POSICION_PERFIL_RASTA = LADERA CONVEXA	1
POSICION_PERFIL_RASTA = LADERA CONCAVA	1
ESTRUCTURA_RASTA = MA1VA	1
OBSERVA_PLANTAS_PEQUENAS_RASTA = PLANTAS ORMALES	1
OBSERVA_PLANTAS_PEQUENAS_RASTA = POCO AFECTADAS	1
OBSERVA_PLANTAS_PEQUENAS_RASTA = MUY AFECTADAS	1
drenaje_externo = LENTO	1
COLOR_ENDOSPERMO	1
DRENAJE	1
CAP_ENDURE_RASTA	1
POBLACION_20DIAS_AJT	1
ContEnfQui_Emer_Flor	1

SELECCIÓN DE ATRIBUTOS – 30

attribute	wei... ↓
ContEnfQui_Emer_Flor	1
ContMalMec_Siem_Emer	1
ContPlaQui_Antes_Siem	1
ESPESOR_CAP_ENDURE_RASTA	1
Porc_Ar	1
Porc_PLASTICO	1




MODELADO

Selección de la técnica del Modelado



Algoritmos Supervisados:

- *Regresión Lineal*
- *Arboles de decisión*
- *Support vector - Machine*



Algoritmos No supervisados

- *Clustering k-Means*



CLR (CLUSTER-WISE LINEAR REGRESSION)






Fig 1: Algoritmo Clusterwise Linear Regression, tomado [1]

EVALUACIÓN DE LA CALIDAD DEL ALGORITMO CLR





Cluster 1	→	R-AJUSTADO 1
Cluster 2	→	R-AJUSTADO 2
Cluster 3	→	R-AJUSTADO 3

Coeficiente de determinación [R^2] determina que tan bien se ajustan los datos al modelo $[0,1]$

$$R - ADJ_{Total} = \frac{(R - ADJ_1 * NOCL1) + (R - ADJ_2 * NOCL2) + (R - ADJ_3 * NOCL3) + (R - ADJ_n * NOCLn)}{\# Total Observaciones}$$

2. METAHURISTICA

ALGORTIMOS GENETICOS



```

2:  $P \leftarrow \{\}$ 
3: for popsize times do
4:    $P \leftarrow P \cup \{\text{new random individual}\}$ 
5:  $Best \leftarrow \square$ 
6: repeat
7:   for each individual  $P_i \in P$  do
8:     AssessFitness( $P_i$ )
9:     if  $Best = \square$  or  $Fitness(P_i) > Fitness(Best)$  then
10:       $Best \leftarrow P_i$ 
11:     $Q \leftarrow \{\}$  ▷ Here's
12:    for popsize/2 times do
13:      Parent  $P_a \leftarrow \text{SelectWithReplacement}(P)$ 
14:      Parent  $P_b \leftarrow \text{SelectWithReplacement}(P)$ 
15:      Children  $C_a, C_b \leftarrow \text{Crossover}(\text{Copy}(P_a), \text{Copy}(P_b))$ 
16:       $Q \leftarrow Q \cup \{\text{Mutate}(C_a), \text{Mutate}(C_b)\}$ 
17:     $P \leftarrow Q$ 
18: until  $Best$  is the ideal solution or we have run out of time
19: return  $Best$ 
  
```

Fig 2: pseudocódigo algoritmo evolutivo, tomado de [5]

REPRESENTACIÓN DE LA SOLUCIÓN

Numero Registros Dataset									
	1	2	3	4	5	6	7	8 747
1	1	2	2	4	5	5	3	4 5
2	5	1	3	1	5	1	3	4 5
3	2	1	1	1	4	4	5	4 3
4	3	2	2	5	5	1	3	4 3
N	4	4	2	4	1	5	3	3 3

N: Tamaño Población

Fig 3: Solución discreta. Fuente propia

FUNCIÓN OBJETIVO

1	2	3	4	5	6	7	8	747
1	2	2	4	5	5	3	4	5



C1



C1



C3



C4



C5

$$R - ADJ_{Total} = \frac{(R - ADJ_1 * NOCL1) + (R - ADJ_2 * NOCL2) + (R - ADJ_3 * NOCL1) + (R - ADJ_n * NOCLn)}{\# Total Observaciones}$$

FUNCIÓN OBJETIVO

```
def fitnessIndividuo(df,individuo,Clusters,NEFO):  
  
    listFitness = []  
    # Se realizan los respectivos filtros  
    for i in range(Clusters):  
        vectorArray = np.array(individuo)  
        clus = np.where(vectorArray == (i+1))  
        list_cls = clus[0].flatten().tolist()  
        # Se filtra el dataset de acuerdo a esos índices  
        df_cls = df[df.index.isin(list_cls)==True]  
        # Se realiza el llamado a la función lineal  
        fitness_cls = RegresionLineal(df_cls)  
        listFitness.append(fitness_cls)  
  
    # Fitness solución | Individuo  
    FitnessSolucion = sum(listFitness)/len(df)  
    # Actualizo el contador  
    NEFO = NEFO+1  
    return FitnessSolucion,NEFO
```

Pasos

- Filtro el individuo para c/d cluster
- Obtengo el modelo de regresión lineal para los datos del cluster
- Obtengo el fitness de la solución, asociada c/d individuo.

Fig 4: Función Objetivo, Fuente Propia

FUNCIÓN OBJETIVO

```
def RegresionLineal(df_cls):  
    Pond_Radjustado = len(df_cls)  
    # Se divide el dataset en conjunto de entrenamiento y pruebas [0.7 : Entrenamiento; 0.3: Testeo]  
    data_train, data_test = train_test_split(df_cls, test_size=0.3, random_state=42)  
    variables_independientes = '''~ C(MATERIAL_GENETICO) + C(TIPO_MATERIAL) +C(POSICION_PERFIL_RASTA) +C(ESTRUCTURA_RASTA)  
    + C(OBSERVA_COSTRAS_BLANCAS_RASTA) + C(OBSERVA_COSTAS_NEGRAS_RASTA) + C(OBSERVA_PLANTAS  
    + C(TIPO_SIEMBRA)+ C(SEM_TRATADAS) + C(DIAS_EN_FLORECER_A_COSECHAR) +ContEnfQui_Emer_Fl  
    + ContPlaQui_Siem_Emer + PROFUND_RAICES_VIVAS_RASTA + Porc_Ar + Porc_FAr + Porc_BLANDO  
    ...  
    # Se crea el modelo  
    mod_cls = smf.ols(formula='RDT_AJUSTADO'+variables_independientes, data=data_train).fit()  
    #Me retorna el valor de la metrica de desempeño para ese cluster.  
    fitnes_cls = mod_cls.rsquared_adj * Pond_Radjustado  
    return fitnes_cls
```

Fig 5: Modelo regresión Lineal, fuente propia

Pasos

- Divido los datos de c/d cluster en [Entrenamiento y Testeo]
- Obtengo el valor rsquared_adj

PSEUDOCODIGO

VARIABLES -PARAMETROS

```
popSize=100          # Se define el tamaño de la población
Clusters = 5         # Numero de Clusters
P = []               # Lista donde se va almacenar la poblacion.
FitnessPobl = []     # Lista vacia que almacena Valores FO
Best = []            # Mejor solucion de ajuste
QBest = 0            # Calidad del best Inicial
NEFO = 0             # Contador Numero de Evaluaciones FO
nDim = len(df)       #Numero de Observaciones del dataset.

# Crea la poblacion
P, FitnessPobl, NEFO = crearPoblacion(popSize, nDim, Clusters, NEFO)
```

```

repeat
    for each individuo (pi) C P do:
        if (len(Best) == 0) or (FitnesPobl[z] > QBest):
            Best = P[z]
            QBest = FitnesPobl[z]

    if (NEFO == 5000):
        break

Q = []
FitnesQ = []
for i in range(int(popSize/2)):
    # Seleccion padres
    Padre1, Padre2 = seleccionPadres(popSize, P)
    # Cruce
    c1, c2 = cruzeHijos(Padre1, Padre2)
    # Mutacion
    Mc1, Mc2, QMc1, QMc2, NEFO = mutacionIntercambio(c1, c2, NEFO)
    # Agregamos los cruces a la nueva Poblacion
    Q.append(Mc1)
    Q.append(Mc2)
    # Se obtienen los Fitnes de la nueva Poblacion
    FitnesQ.append(QMc1)
    FitnesQ.append(QMc2)

# Reemplazo la nueva poblacion y la Funcion de ajuste
P = Q
FitnesPobl = FitnesQ

```

Hasta Best solucion ideal (Best < 0.9) or NEFO = 5000

ALGUNAS FUNCIONES

```
# Funcion para crear la poblacion
# =====
def crearPoblacion(popSize,nDim,Clusters,NEFO):
    for i in range(popSize):
        #print(i)
        # Creo el individuo
        individuo = vectorSolution(nDim, Clusters)
        P.append(individuo)
        # Evaluo el individuo (Fitness)
        FitInd = fitnessIndividuo(df,individuo,Clusters,NEFO)
        # Agrego el ajuste a lista de Fitness de la población
        NEFO = FitInd[1]
        FitnesPobl.append(FitInd[0])

    return P,FitnesPobl,NEFO
```

Fig 6: función crear población, fuente propia

ALGUNAS FUNCIONES

```
# Funcion  Seleccion de Padres  (Aleatoria)      # paso poblacion
# =====
def seleccionPadres(popSize,Poblacion):
    # Se genrar una lista con el Tamaño de la poblacion
    tamanoPoblacion = list(range(popSize))
    padres = np.random.choice(tamanoPoblacion, 2, False)
    Padre1 = Poblacion[padres[0]]
    Padre2 = Poblacion[padres[1]]

    return Padre1,Padre2
```

Fig 7. Función selección padres, fuente propia

ALGUNAS FUNCIONES

```
# Funcion para remplazar la nueva Poblacion - Operador del peor
# =====
def RemplazoDelPeor(fitP,fitNP,Poblacion,NuevaPoblacion):
    # Agrupamos en una sola lista el fitness de ambas poblaciones
    fitT = fitP + fitNP
    # Agrupamos en una sola lista las poblaciones
    PT = Poblacion + NuevaPoblacion
    # Se convierte la lista de Fitnes Total a df
    df = pd.DataFrame(fitT,columns=["Fitnes"])
    # Obtengo los N mejores individuos de acuerdo al tamaño de la población
    df = df.sort_values('Fitnes',ascending=False)[0:len(fitP)]
    # Lista de los mejores valores de Aptitud
    Nfit = list(df.Fitnes)
    # Lista de los índices de la Población
    indexNuevaPoblacion = list(df.index)
    # Ubicamos los Individuos de la Nueva Población

    NP = []
    for i in range(len(indexNuevaPoblacion)):
        NP.append(PT[indexNuevaPoblacion[i]])

    # Retorna la lista de la nueva Poblacion y los respectivos Fitnes
    return NP, Nfit
```

Fig 8. Función remplazo del peor, fuente propia

4. RESULTADOS

CONFIGURACION DE ALGORTIMOS

Algoritmos	Operadores			
	Selección	Cruce	Mutación	Remplazo
A1	Aleatoria	Un Punto	Intercambio	De Padres
A2	ELitismo	Un punto	Intercambio	Del peor

Tabla 1: Tabla de Configuraciones de algoritmos

ANALISIS DE RESULTADOS

Algoritmo 1	
Población	Fitness
50	0.6249
100	0.6379
200	0.6384

Tabla 2: Resultados configuración 1

Algoritmo 2	
Población	Fitness
50	0.6047
100	0.6284
200	0.6512

Tabla 3: Resultados configuración 1

5.CONCLUSIONES

- Para el calculo de la función objetivo (fitness) y crear cada uno de los submodelos (Regresión Lineal) únicamente se tuvo en cuenta las 30 características mas significativas del dataset. Seria importante analizar el desempeño del modelo incluyendo mas características (Categóricas y numéricas).
- La solución **Qbest** nos muestra el mejor valor de ajústate para el macromodelo, teniendo en cuenta los valores de ajuste (R^2) de cada uno de los micromodelos.
- La implementación de los algoritmos genéticos se realiza con el fin de determinar la mejor distribución de las observaciones en cada uno de los clusters, de tal manera que se maximice la función objetivo.

6.BIBLIOGRAFIA

- [1]https://www.researchgate.net/publication/324859471_Novel_Prediction_Techniques_Based_on_Clusterwise_Linear_Regression
- [2]Algoritmos genéticos teoría, <https://conogasi.org/articulos/algoritmos-geneticos/>
- [3]Librerías Python, <https://www.programiz.com/python-programming/methods/list/index>
- [4] <http://www.cs.us.es/~fsancho/?e=65>
- [5] Diapositivas de Clase , Materia Metahurísticas.



Por una
universidad
de **excelencia**
y **solidaria**



Universidad
del Cauca

***¡Gracias por
su atención!***

www.unicauca.edu.co